$$\boxed{b_0(x) = \beta^\top m(x)}$$

是一个通过数据拟合得到的**状态相关感知误差包络函数**（State-Dependent Error Envelope）。

它的计算需要完成三个主要步骤：

1. **计算感知残差** r_i：测量低维视觉观测与物理状态参考观测之间的误差。
2. **构造状态多项式特征** $m(x)$：将物理状态映射到预先定义的多项式基空间。
3. **通过凸优化求解系数** β：使 $b_0(x_i)$ 尽可能覆盖样本残差，同时避免误差界过于保守。

注意： $b_0(x)$ 不是 DINOv2 网络直接输出的值，而是利用状态—图像配对数据训练出来的误差估计函数。

一、第一步：从图像和真实状态计算感知残差

假设有训练数据：

$$\mathcal{D} = \{(x_i, I_i)\}_{i=1}^{N}.$$

其中：

- $x_i \in \mathbb{R}^{n_x}$：真实物理状态；
- I_i：与该状态对应的 RGB 图像。

VISION-SLS 使用 DINOv2 和投影网络计算低维视觉观测：

$$y_i^r = p_\theta(\psi_{\text{DINO}}(I_i)).$$

同时，通过学习得到的线性状态观测模型：

$$h_r(x_i) = C_r x_i$$

计算对应的理想低维观测。于是第 i 个样本的感知残差为：

$$\boxed{r_i = \left\| p_\theta(\psi_{\text{DINO}}(I_i)) - C_r x_i \right\|_\infty .} \tag{1}$$

例如，若低维视觉观测为：

$$y_i^r = \begin{bmatrix} 1.12 \\ 0.85 \\ 0.43 \end{bmatrix}, \qquad C_r x_i = \begin{bmatrix} 1.10 \\ 0.90 \\ 0.40 \end{bmatrix},$$

则：

$$r_i = \max(0.02, 0.05, 0.03) = 0.05.$$

对所有样本重复这个过程，得到：

$$\{(x_1, r_1), \dots, (x_N, r_N)\}.$$

这就把原来的高维 RGB 感知误差建模问题，转化为一个**从低维物理状态预测非负残差上界**的问题。

二、第二步：构造多项式基向量 $m(x)$

这一环节决定误差包络 $b_0(x)$ 采用什么函数形式。

2.1 最简单的情况：一维状态

假设误差主要与车辆的横向位置 x 有关。如果采用二阶多项式：

$$b_0(x) = \beta_0 + \beta_1 x + \beta_2 x^2,$$

那么：

$$\boxed{m(x) = \begin{bmatrix} 1 \\ x \\ x^2 \end{bmatrix}, \qquad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}.}$$

因此：$b_0(x) = \beta^\top m(x)$。计算时，只需将状态值代入多项式，再与学习得到的系数相乘。

2.2 VISION-SLS 的车辆实例：二维位置、三阶多项式

论文附录 D.3 的车辆实验中，状态为：

$$x = \begin{bmatrix} p_x & p_y & \theta & v \end{bmatrix}^\intercal.$$

但构建感知误差包络时，使用的是位置变量 p_x, p_y，并采用三阶单项式基。

按照标准的总次数不超过三阶的多项式展开，可以构造：

$$\boxed{m(p_x, p_y) = \begin{bmatrix} 1 \\ p_x \\ p_y \\ p_x^2 \\ p_x p_y \\ p_y^2 \\ p_x^3 \\ p_x^2 p_y \\ p_x p_y^2 \\ p_y^3 \end{bmatrix}.}$$

因此 $m(x) \in \mathbb{R}^{10}$，待学习参数 $\beta \in \mathbb{R}^{10}$。

完整的误差包络为：

$$\begin{aligned} b_0(p_x, p_y) = \beta_0 &+ \beta_1 p_x + \beta_2 p_y \\ &+ \beta_3 p_x^2 + \beta_4 p_x p_y + \beta_5 p_y^2 \\ &+ \beta_6 p_x^3 + \beta_7 p_x^2 p_y \\ &+ \beta_8 p_x p_y^2 + \beta_9 p_y^3. \end{aligned}$$

这里列出的是标准完整三阶基的实现方式；原论文说明了多项式阶数和所使用的状态变量，但未在该处逐项列出全部单项式。

2.3 如何选择多项式阶数?

多项式阶数	二维状态的基函数数量	特点
一阶	3	简单，但只能描述线性误差趋势
二阶	6	能描述部分非线性变化
三阶	10	表达能力与优化复杂度相对均衡
四阶	15	更灵活，但更容易过拟合

对于 d 维状态和总次数不超过 k 的完整多项式基，基函数数量为:

$$\boxed{M = \binom{d+k}{k}.}$$

VISION-SLS 的四旋翼实验使用了与 $p_x, p_y, p_z, \theta_x, \theta_y$ 相关的四阶单项式基。如果采用这五个变量的完整总次数四阶基，则需要:

$$M = \binom{9}{4} = 126$$

个基函数。实际实施时，也可以只选择部分有物理意义的交叉项，以减少拟合参数和验证复杂度。

三、第三步：通过凸优化计算 β

这一步是整个计算过程的核心。

3.1 构建设计矩阵

对于 N 个样本，先计算 $m(x_1), m(x_2), \dots, m(x_N)$，构造矩阵:

$$\boxed{M = \begin{bmatrix} m(x_1)^\top \\ m(x_2)^\top \\ \vdots \\ m(x_N)^\top \end{bmatrix} \in \mathbb{R}^{N\times p}.}$$

其中 p 是多项式基函数数量。残差向量:

$$r = \begin{bmatrix} r_1 \\ r_2 \\ \vdots \\ r_N \end{bmatrix}.$$

则所有样本的预测误差界为:

$$\boxed{b = M\beta.}$$

目标是找到系数 β，使 $M\beta \geq r$ 尽可能成立，同时让预测误差界总体较小。

3.2 VISION-SLS 的原始优化问题

论文式（31）采用：

$$\begin{aligned} \min_{\beta,\xi} \quad & \sum_{i=1}^{N} \beta^\top m(x_i) + \gamma\|\beta\|_2^2 + \mu \sum_{i=1}^{N} \xi_i \\ \text{s.t.} \quad & \beta^\top m(x_i) \geq r_i - \xi_i, \quad \forall i, \\ & \xi_i \geq 0. \end{aligned} \tag{2}$$

各项的作用如下。

项	含义
$\sum_i \beta^\top m(x_i)$	尽可能降低预测误差包络的总体大小
$\gamma\|\beta\|_2^2$	抑制过大的多项式系数
$\mu \sum_i \xi_i$	惩罚残差超过误差包络的情况
$\beta^\top m(x_i) \geq r_i - \xi_i$	约束拟合包络与真实残差的关系
$\xi_i \geq 0$	允许少量样本违反严格覆盖约束

将其改写为矩阵形式：

$$\begin{aligned} \min_{\beta,\xi\geq 0} \quad & \mathbf{1}^\top M\beta + \gamma\beta^\top\beta + \mu\mathbf{1}^\top\xi \\ \text{s.t.} \quad & M\beta + \xi \geq r. \end{aligned} \tag{3}$$

当 $\gamma \geq 0, \mu \geq 0$ 时，目标函数是凸的，约束是线性的，因此可以使用标准凸优化求解器计算 β。

特别注意：实现时还应保证 $b_0(x)$ 在使用的状态范围内非负。仅在训练样本上约束非负，不能保证多项式在整个状态域内非负；必要时应使用区域约束、分片界验证或其他非负性保证技术。

四、一个能够手工计算的例子

先使用一维线性函数说明计算原理。

假设：

$$m(x) = \begin{bmatrix} 1 \\ x \end{bmatrix}.$$

通过视觉数据得到：

样本	状态 x_i	感知残差 r_i
1	0	0.04
2	1	0.06
3	2	0.08

希望拟合：

$$b_0(x) = \beta_0 + \beta_1 x.$$

采用不允许松弛、暂不考虑正则化的简化优化问题：

$$\begin{aligned} \min_{\beta_0,\beta_1} \quad & 3\beta_0 + 3\beta_1 \\ \text{s.t.} \quad & \beta_0 \geq 0.04 \\ & \beta_0 + \beta_1 \geq 0.06 \\ & \beta_0 + 2\beta_1 \geq 0.08. \end{aligned}$$

由于所有样本的残差刚好位于同一条直线上，最优的零松弛解可以取为：

$$\boxed{\beta = \begin{bmatrix} 0.04 \\ 0.02 \end{bmatrix}.}$$

因此得到：

$$\boxed{b_0(x) = 0.04 + 0.02x.}$$

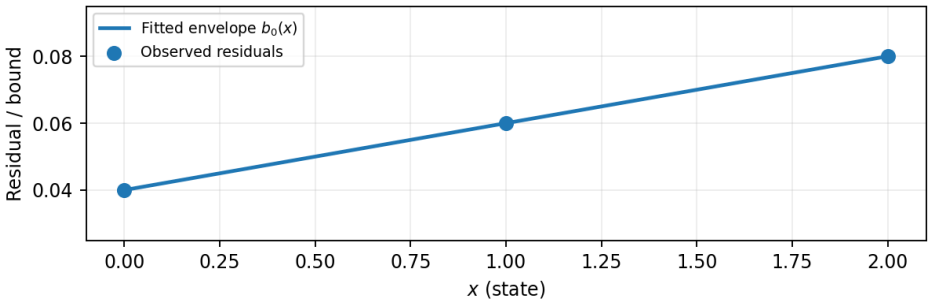


图 1: 状态相关误差包络：示例残差恰好位于拟合的一阶包络上。该图为说明性数据，不是论文实验结果。

如果新状态 $x = 1.5$，模型给出 $b_0(1.5) = 0.07$。这只是拟合得到的预测界，并不自动保证未来观测误差一定不超过 0.07。

五、用 Python 实际计算 β

下面给出可以直接用于二维状态、三阶多项式的 CVXPY 实现。假设已经计算了状态矩阵 `X` 和相应的感知残差 `r`。

```
import numpy as np
import cvxpy as cp
from sklearn.preprocessing import PolynomialFeatures

# X: shape = (N, 2), columns = [px, py]
# r: shape = (N,), DINO 投影的无穷范数残差
X = np.asarray(X, dtype=float)
r = np.asarray(r, dtype=float)
```

```python
# 1. 建立完整三阶多项式基
poly = PolynomialFeatures(degree=3, include_bias=True)
M = poly.fit_transform(X)
N, p = M.shape

# 2. 定义优化变量
beta = cp.Variable(p)
xi = cp.Variable(N, nonneg=True)

# 3. 每个训练样本对应的误差包络
b = M @ beta

# 4. 超参数（示例，可通过验证集调整）
gamma = 1e-4
mu = 20.0

# 5. 凸优化
objective = cp.Minimize(
    cp.sum(b) / N
    + gamma * cp.sum_squares(beta)
    + mu * cp.sum(xi) / N
)
constraints = [
    b + xi >= r,
    b >= 0
]

problem = cp.Problem(objective, constraints)
problem.solve(solver=cp.OSQP)

if problem.status not in ["optimal", "optimal_inaccurate"]:
    raise RuntimeError(problem.status)

beta_hat = beta.value
print("Learned coefficients:", beta_hat)

# 6. 新状态计算误差包络
x_new = np.array([[1.0, 2.0]])
m_new = poly.transform(x_new)

b0 = float((m_new @ beta_hat).item())
print("Predicted error envelope:", b0)
```

上述代码与论文式（31）具有相同的基本优化结构，但将目标按样本数归一化，并添加了训练样本上的非负约束。它适合作为实现起点，并不包含整个状态域上的多项式非负性证明。

由于优化变量只有 β 和松弛变量 ξ，DINOv2 不需要在这个凸优化过程中反向传播。视觉编码器和 C_r 应当先训练完成并固定。

参数 γ, μ 如何选择?

- γ 太大：多项式系数受到较强约束，可能欠拟合。
- γ 太小：高阶系数可能较大，在训练区域之外容易出现不合理波动。

- μ 太小：优化器倾向于使用较大的松弛变量，误差包络可能低估真实残差。
- μ 太大：更强调覆盖训练样本，可能使误差包络保守。

这些超参数应通过独立验证数据调整，而不是简单沿用示例值。另外，位置、姿态等状态变量应先进行适当归一化，避免不同物理量尺度差异导致多项式拟合病态。

六、如果进一步使用 Conformal Prediction，应该如何处理 $b_0(x)$?

这里需要区分两个阶段：

$$\boxed{\underbrace{b_0(x) = \beta^\top m(x)}_{\text{误差尺度拟合}} \longrightarrow \underbrace{b_{\text{CP}}(x)}_{\text{保形校准后的统计误差界}}}.$$

原始的 $b_0(x)$ 是由优化拟合得到的经验误差包络。如果希望为低维视觉观测建立有限样本统计覆盖保证，可以将其作为 CP 的误差尺度模型。

6.1 构造归一化残差

在独立 CP 校准数据上计算：

$$a_i = \frac{r_i}{\max\{\epsilon_0, b_0(x_i)\}}.$$

其中 $\epsilon_0 > 0$ 防止分母为零。

根据给定的覆盖目标 $1-\alpha$，计算 Split CP 校准分位数：

$$q_\alpha = a_{(\lceil (N_{\text{cal}}+1)(1-\alpha) \rceil)}.$$

如果索引超过校准样本数，采用标准的 $+\infty$ 约定。

6.2 构造最终统计误差界

$$\boxed{b_{\text{CP}}(x) = q_\alpha \max\{\epsilon_0, b_0(x)\}.}$$

从而得到低维观测集合：

$$\boxed{Y_{\text{CP}}(x) = \{y : \|y - C_r x\|_\infty \le b_{\text{CP}}(x)\}\,.}$$

在固定编码器、误差尺度模型且校准与测试样本满足交换性时：

$$\boxed{\mathbb{P}\left(\|\phi(I) - C_r X\|_\infty \le b_{\text{CP}}(X)\right) \ge 1-\alpha.}$$

这是对随机测试观测的**边际覆盖保证**，而不是对所有状态的确定性误差保证。若用于 SPVT 的整条控制轨迹，应进一步使用之前讨论的轨迹级 CP 校准。

最重要的结论是:

状态—图像配对数据
$\Downarrow$
$r_i = \|\phi(I_i) - C_r x_i\|_\infty$
$\Downarrow$
构造多项式矩阵M
$\Downarrow$
凸优化求解β
$\Downarrow$
$b_0(x) = \beta^\top m(x)$
$\Downarrow$
独立 CP 校准得到$b_{\mathrm{CP}}(x)$

其中，**凸优化**解决误差包络的状态相关拟合问题，**Conformal Prediction** 解决未见随机样本上的统计覆盖问题